

DAY 1

≡ 다중 선택

EDA

제출용

데이터와 전처리

사용 데이터

구분	파일	원본 셀 수	사용 셀 수	용도
Batch 1	2017-05-12	46	41	학습
Batch 2	2018-02-20	47	39	테스트
Batch 3	2018-04-12	46	40	추가 테스트

- Batch 1, 3은 원논문(Severson et al., 2019)의 2017-05-12, 2018-04-12 배치와 같음. 정제 후 셀 수 (41, 40)와 수명 범위(534 ~ 2237, 541 ~ 1935)가 원논문 Supplementary Table 9와 일치
- Batch 2(2018-02-20)는 원논문에 없는 배치. 원논문의 두 번째 배치는 2017-06-30(43개 셀, 수명 148 ~ 713)이며 이 데이터셋에는 포함되어 있지 않음
 - 가이드의 "150 ~ 2,300 사이클"은 원논문 전체 124개 셀의 범위이고, 150 부근의 셀은 2017-06-30 배치에 있음 -> 이 데이터의 실제 범위는 392 ~ 2237
 - 원논문 성능(9.1%)과 비교할 때 테스트 배치가 다르다는 점을 고려해야 함

셀 제외 (수명을 알 수 없거나 품질 문제가 있는 셀)

배치	제외	사유	근거
Batch 1	5개 (셀 8, 10, 12, 13, 22)	0.88 Ah에 도달하기 전에 실험 종료 -> 실제 수명을 알 수 없음	원논문 공식 코드
Batch 2	8개	<code>cycle_life</code> 값이 없음 (정책명이 VarCharge, SLOWCYCLE인 실험용 셀)	자체 판단
Batch 3	6개 (셀 2, 23, 32, 37, 42, 43)	측정 노이즈, EOL 미도달	원논문 공식 코드

값 보정

대상	처리	근거
Batch 1의 cycle 1	제외. 측정값 없이 0으로 채워져 있음	원논문이 모든 피처를 cycle 2부터 정의
Batch 1의 셀 0 ~ 4 수명	662, 981, 1060, 208, 482 사이클을 더함. 실험이 다음 배치로 이어져 파일의 값이 실제 수명보다 짧음	원논문 공식 코드. 보정 후 값이 Table 9와 일치
방전 용량 1.3 Ah 초과	결측 처리. 공칭 용량 1.1 Ah인 셀에서 나올 수 없는 값	자체 판단
내부저항 0 Ω	결측 처리. 측정 누락	자체 판단


대상	처리	근거
충전 시간	초기 100 사이클의 중앙값으로 집계. Batch 1의 3개 셀에 약 419분으로 기록된 값이 있음 (정상 약 11분)	자체 판단

기준

- EOL : 공칭 용량 1.1 Ah의 80%인 0.88 Ah. 데이터의 `cycle_life` 가 이 기준으로 산정되어 있음 (Batch 2의 39개 셀에서 0.88 Ah 최초 도달 사이클과 `cycle_life` 가 모두 일치)
- 제외한 셀 중 수명이 짧은 셀은 없음 -> 짧은 수명 구간을 전처리로 잘라낸 것이 아님

Question 1-5

1. `cycle_life` 분포는 어떻게 생겼는가?



	count	mean	std	min	25%	50%	75%	max
batch								
Batch 1	41.0	921.3	400.8	534.0	702.0	842.0	966.0	2237.0
Batch 2	39.0	565.7	222.2	392.0	439.5	472.0	508.5	1186.0
Batch 3	40.0	1032.0	308.6	541.0	827.2	964.5	1122.8	1935.0

1.1. 150 ~ 2,300 사이클 Histogram

각 Batch의 분포가 확연히 다를 수 있다. 특히 Batch 2의 경우 `cycle_life`의 값이 550 미만에 분포되어 있어 Batch 1, 3과 거의 겹치지 않는다.

1.2. 장수명(>1,000)/단수명(<500) 비율 확인


- 장수명 : Batch 1 24% (10개) / Batch 2 8% (3개) / Batch 3 48% (19개)
- 단수명 : Batch 1 0% / Batch 2 72% (28개) / Batch 3 0%

Batch 1-3에는 단수명 셀이 하나도 없고, Batch 2는 대부분이 단수명이다.

특히, Classification 기준인 550 미만으로 보면 2% (1개) / 77% (30개) / 2% (1개) 로 분포가 매우 불균형

함을 확인할 수 있다.

1.3. 이상치 셀 식별 - 왜 유독 짧은가?



Box plot 기준, 이상치는 모두 장수 셀에 분포되어 있다. 각 Batch 별 이상치에 대한 특징은 다음과 같다.

- Batch 1 : 5개 (1434 ~ 2237). 가장 느린 충전 정책 2종의 셀
- Batch 2 : 9개 (777 ~ 1186). 모두 정책명에 `newstructure` 가 붙은 셀
- Batch 3 : 4개 (1638 ~ 1935)


배치별 최단 셀 2개

	batch	cell_id	cycle_life	charging_policy	med_chargetime
60	Batch 2	19	392	6C(60%)-3C	10.174563
47	Batch 2	6	393	3.6C(9%)-5C	10.179361
16	Batch 1	20	534	5.4C(80%)-5.4C	9.006340
106	Batch 3	28	541	3.7C(31%)-5.9C-newstructure	10.083590
17	Batch 1	21	559	5.4C(80%)-5.4C	8.985737
85	Batch 3	6	667	3.7C(31%)-5.9C-newstructure	10.077624

- Batch 1의 최단 셀은 `med_chargetime` 이 약 9.0분으로, 약 10분인 Batch 2·3의 최단 셀보다 짧다. 배치 내에서 가장 빠른 충전 조건(`5.4C(80%)-5.4C`)이며, 수명이 짧은 이유가 **충전 속도**로 설명된다.
- Batch 2와 Batch 3의 최단 셀은 `med_chargetime` 이 10.1 ~ 10.2분으로 거의 같다. 그런데 수명은 Batch 2가 392, 393이고 Batch 3가 541, 667로 다르다. 충전 시간만으로는 이 차이를 설명할 수 없다.
- Batch 2는 서로 다른 정책의 두 셀이 392, 393으로 거의 같다. 특정 정책이 아니라 배치 전체가 짧다는 것을 보여 준다.

2. 열화 곡선 - 방전 용량이 어떻게 감소하는가?

2.1. 사이클 별 Qd 추이 시각화



세 배치 모두 방전 용량이 1.05 ~ 1.10 Ah에서 시작해 오랫동안 평탄하게 유지되다가, 수명 말기에 급락해 EOL(0.88 Ah)에 도달한다.

배치	EOL 도달 구간	특징
Batch 1	500 ~ 1100 사이클	장수 셀 5개는 약 1200 사이클에서 곡선이 끊긴다 (이후 구간 데이터 없음).
Batch 2	대부분 400 ~ 500 사이클	30개 셀이 좁은 구간에 몰려 급락한다. newstructure 9개 셀만 800 ~ 1200 사이클까지 유지된다.
Batch 3	500 ~ 1900 사이클	넓은 구간에 고르게 퍼져 있다.

초반에는 장수 셀(파랑)과 단명 셀(빨강)의 곡선이 겹쳐 있어, 초기 용량만으로는 수명을 구분하기 어렵다.

2.2. 열화 속도가 일정한가, 가속되는가?

일정하지 않고, 세 배치 모두 수명 말기에 가속된다.

	Batch 1	Batch 2	Batch 3
수명 전반부 50% 동안의 용량 감소 비중	8%	3%	10%
마지막 100 사이클의 용량 감소 비중	48%	71%	50%
cycle 100 용량이 cycle 2보다 높은 셀 비율	90%	64%	85%


(EOL에 도달한 셀 기준, 중앙값)

- 수명의 절반이 지날 때까지 일어나는 용량 감소는 전체의 3 ~ 10%에 불과하다.
- 전체 감소량의 절반 이상이 마지막 100 사이클에 집중된다.
- 초기 100 사이클에는 열화가 거의 없고, 대부분의 셀은 오히려 용량이 약간 증가한다.

열화가 가속형이므로, 초기 구간의 감소율을 선형으로 연장해 수명을 추정하는 방식은 맞지 않는다.

2.3. Knee point - 급격한 열화 시작점 탐색

Knee point를 "방전 용량이 1.0 Ah 아래로 내려간 뒤 다시 회복하지 않는 첫 사이클"로 정의해 셀마다 구했다. 세 배치 모두 knee point가 존재하며, 대부분 수명의 80 ~ 88% 지점에서 나타난다.



그래프. 배치별로 수명이 가장 짧은 셀, 중간인 셀, 가장 긴 셀의 열화 곡선을 굵게 표시했다. 큰 점(●)이 knee point이고, 색 띠는 knee에서 EOL까지의 구간이다. 회색 선은 나머지 셀이다. (괄호 안은 knee 시점 / 수명)

배치	최단 셀	중간 셀	최장 셀
Batch 1	수명 534, knee 323 (60%)	수명 757, knee 634 (84%)	수명 1074, knee 921 (86%)
Batch 2	수명 392, knee 345 (88%)	수명 472, knee 399 (85%)	수명 1186, knee 965 (81%)

배치	최단 셀	중간 셀	최장 셀
Batch 3	수명 541, knee 250 (46%)	수명 1002, knee 873 (87%)	수명 1935, knee 1549 (80%)

- knee point의 위치는 셀마다 크게 다르다. 가장 이른 셀은 250 사이클, 가장 늦은 셀은 1549 사이클이다.
- 반면 knee 이후의 색 띠는 폭이 좁고 서로 비슷하다. 급락이 시작되면 수명과 관계없이 짧은 시간 안에 EOL에 도달한다.
- Batch 1과 Batch 3의 최단 셀은 예외다. 초기부터 용량이 서서히 감소해 knee가 수명의 46 ~ 60% 지점에서 나타나고, 색 띠도 넓다.

전체 셀 기준 (중앙값) 각 배치의 Knee point는 다음과 같다.

	Batch 1	Batch 2	Batch 3
Knee point (사이클)	637.5	404	841.5
Knee 시점 / 수명	0.83	0.87	0.82
Knee에서 EOL까지 (사이클)	135	65	163

- Knee point와 수명의 상관계수는 0.986이다. 수명은 사실상 knee가 언제 시작되느냐로 결정된다.
- Batch 2는 knee 이후 65 사이클 만에 EOL에 도달해 가장 가파르게 떨어진다.
- 가장 빠른 knee도 250 사이클 이후에 나타난다. 초기 100 사이클 안에는 어떤 셀에도 knee가 나타나지 않는다.

수명을 결정하는 knee의 시작 시점은 초기 100 사이클의 용량 곡선에는 아직 드러나지 않는다. 따라서 초기 용량 곡선만으로는 수명을 예측할 수 없고, 다른 초기 신호가 필요하다.

3. $\Delta Q(V)$ 곡선 - 초기 사이클에서 차이가 보이는가?


3.1. 사이클 100번 - 사이클 10번의 $Q(V)$ 차이 계산

Q_{dlin} 은 방전 용량을 같은 전압 1,000개 지점(3.5 V → 2.0 V)에 맞춰 보간한 값이다. 모든 사이클이 같은 전압 지점을 쓰므로 두 사이클의 곡선을 지점별로 뺄 수 있다.

$$\Delta Q(V) = Q_{dlin}(\text{cycle } 100) - Q_{dlin}(\text{cycle } 10)$$

셀 하나당 1,000개 값으로 이루어진 곡선 하나가 나오며, 세 배치 120개 셀 모두에 대해 계산했다.

3.2. 장수명 셀 vs 단수명 셀의 ΔQ 형태 비교




장수명 셀과 단수명 셀은 $\Delta Q(V)$ 곡선의 깊이가 뚜렷이 다르다. 단수명 셀(빨강)은 곡선이 아래로 깊게 내려가고, 장수명 셀(파랑)은 0 근처에 머문다.

(중앙값)	장수명 (>1,000) 32개	중간 46개	단수명 (<700) 42개
$\Delta Q(V)$ 최솟값	-0.022 Ah	-0.029 Ah	-0.056 Ah
$\Delta Q(V)$ 분산	0.00005	0.00009	0.00035

- 단수명 셀의 최솟값은 장수명 셀의 약 2.5배, 분산은 약 7배다.
- 곡선이 가장 깊어지는 전압은 세 배치 모두 2.9 ~ 3.0 V 부근이다. 형태는 같고 깊이만 다르다.
- 세 배치에서 같은 경향이 나타난다. 배치별 단수명 셀의 최솟값은 -0.055, -0.056, -0.056 Ah로 거의 같다.

용량 값(QD)으로는 초기 100 사이클에서 구분되지 않던 장·단수명 셀이, 전압 곡선의 변화인 $\Delta Q(V)$ 에서는 구분된다.

3.3. 이를 구분할 수 있는 통계값으로 피쳐 추출



$\Delta Q(V)$ 곡선(1,000개 값)을 셀당 숫자 하나로 요약하기 위해 분산, 최솟값, 평균을 계산하고, $\log_{10}(\text{cycle life})$ 와의 상관계수를 비교했다.


통계값	Batch 1	Batch 2	Batch 3	전체
$\log_{10}(\text{분산})$	-0.94	-0.92	-0.80	-0.92
최솟값	0.87	0.84	0.75	0.87
평균	0.85	0.79	0.69	0.84

- 분산이 세 배치 모두에서 가장 강하다. 로그를 취하면 수명과 직선에 가까운 관계가 된다 (원논문 -0.93).
- 최솟값과 평균도 강하지만, Batch 1에서 분산과의 상관이 -0.95, -0.93으로 사실상 같은 정보다.
- Batch 2의 -0.92는 **newstructure** 9개 셀과 나머지 30개를 구분하는 효과가 대부분이다. 수명이 392 ~ 514인 30개 셀 안에서는 -0.38로 약해진다.

추출한 피쳐. $\log_{10}(\Delta Q(V))$ 의 분산을 핵심 피쳐로 사용한다. 최솟값과 평균은 분산과 중복되므로 후보로만 두고, 함께 쓸 때는 규제가 있는 모델을 사용한다.

4. 충전 조건 (C-rate)과 수명의 관계는?

4.1. 충전 프로토콜별 평균 수명 비교




충전 프로토콜에 따라 평균 수명이 배치 안에서 2.4 ~ 3.8배 차이 난다.

배치	프로토콜 수	평균 수명이 가장 긴 프로토콜	가장 짧은 프로토콜	배율
Batch 1	22	3.6C(80%) - 3.6C 2083	5.4C(80%) - 5.4C 546	3.8배
Batch 2	12	5.6C(26%) - 4.5C (ns) 991	3.6C(9%) - 5C 394	2.5배
Batch 3	8	4.8C(80%) - 4.8C (ns) 1588	3.7C(31%) - 5.9C (ns) 660	2.4배

(ns = 정책명에 **newstructure** 가 붙은 셀)

- Batch 1 : 상위 2개 프로토콜(2083, 1572)이 나머지(1074 이하)와 크게 떨어져 있다. 둘 다 가장 느린 충전 방식이다.
- Batch 2 : **newstructure** 3개 프로토콜(872 ~ 991)과 일반 9개 프로토콜(394 ~ 484)로 나뉜다. 일반 프로토콜끼리는 차이가 90 사이클에 불과하다.
- Batch 3 : 660 ~ 1588로 넓게 퍼져 있다. 최상위 4.8C(80%) - 4.8C 는 실제 충전 시간이 약 11분으로 4.36C에 해당하며, 원논문 표에도 4.36C(80%) - 4.36C 로 기재되어 있다.
- 프로토콜당 셀이 1 ~ 8개뿐이고 같은 프로토콜 안에서도 편차가 있어(오차 막대), 개별 프로토콜 간 비교는 경향 수준으로 해석해야 한다.

4.2. 고속 충전 셀이 정말 수명이 짧은가?



Batch 1에서는 그렇다. Batch 2와 3은 충전 속도가 거의 같아서 해당 데이터에서는 확인이 어렵다.

Batch 1. 80%까지의 충전 시간이 9.0 ~ 13.4분으로 다양하며, 충전 시간이 짧을수록(고속일수록) 수명이 짧다. 상관계수는 0.79다.

충전 시간 (0% -> 80%)	셀 수	평균 수명	수명 범위
10.5분 이하	16	708	534 ~ 876
10.5 ~ 11.5분	13	848	651 ~ 1074
11.5 ~ 12.5분	9	1019	648 ~ 1709
12.5분 초과	3	2083	1852 ~ 2237

충전 시간이 길어질수록 평균 수명이 708에서 2083으로 늘어난다. 다만 같은 구간 안에서도 수명 범위가 넓어, 충전 속도만으로 수명이 정해지지 않는다.

Batch 2, 3. 그래프에서 두 배치는 10분 부근에 세로로 몰려 있다. Batch 2는 39개 셀 전부, Batch 3는 40개 중 36개가 10.0 ~ 10.3분이다. 충전 속도가 사실상 같은데 수명은 392 ~ 1935로 크게 다르다. 충전 속도 외의 요인이 수명을 좌우한다는 뜻이다.

Batch 2의 상관계수(-0.92)는 충전 시간 차이가 0.2분에 불과한 범위에서 나온 값이고, Batch 3의 상관계수(0.60)는 충전 시간이 약 11분인 4개 셀이 만든 값이다. 둘 다 고속 충전의 효과로 해석할 수 없다.

결론. 고속 충전이 수명을 줄인다는 관계는 충전 속도가 다양한 Batch 1에서만 확인된다. 충전 속도는 Batch 1 안에서는 강한 설명 변수지만, 속도가 일정한 Batch 2와 3에서는 정보가 없다.

4.3. 충전 전류 패턴과 열화 속도 상관 분석

충전 정책 C1(Q1%)-C2를 1단계 속도(C1), 전환 시점(Q1), 2단계 속도(C2)로 나누고, 평균 열화 속도와 상관성을 구했다. 평균 열화 속도는 cycle 2 용량에서 EOL(0.88 Ah)까지의 감소량을 수명으로 나눈 값 (mAh/cycle)이다.

평균 열화 속도와의 상관	Batch 1	Batch 2	Batch 3
1단계 속도 (C1)	0.61	-0.14	-0.04
전환 시점 (Q1)	-0.27	-0.18	-0.50
2단계 속도 (C2)	0.20	0.08	0.42

- **Batch 1 : 1단계 속도가 빠를수록 열화가 빠르다 (0.61).** 같은 1단계 속도에서는 그 구간이 길수록 열화가 빨라진다. 8C를 15%, 25%, 35%까지 쓴 경우 평균 열화 속도가 0.20, 0.29, 0.34 mAh/cycle로 늘어난다.
- **Batch 3 : 2단계 속도가 빠를수록 열화가 빠르다 (0.42).** 느리게 시작해 2단계를 5.9C로 충전하는 3.7C(31%) - 5.9C가 0.28 mAh/cycle로 가장 빠르고, 2단계가 4C인 정책은 0.17 ~ 0.18이다. 초기 100 사이클의 용량 감소와 2단계 속도의 상관은 0.78이다.
- **Batch 2 : 뚜렷한 관계가 없다 (모두 0.2 미만).** 수명이 newstructure 여부로 갈리고, 패턴에 따른 차이는 그에 비해 작다.


배치마다 영향을 주는 패턴 변수가 다르다. Batch 1에서는 1단계 속도, Batch 3에서는 2단계 속도가 중요하고, Batch 2에서는 어느 것도 뚜렷하지 않다. 충전 패턴 변수는 배치 간에 일관된 신호가 아니므로 주 피처로 삼기 어렵다고 판단하였다.

5. 상관관계 - 어떤 신호가 수명과 연관되어 있는가?

5.1. 초기 사이클 피쳐들과 Cycle Life 상관 계수 확인

초기 100 사이클에서 계산한 9개 피쳐와 log10(cycle life)의 상관계수를 배치별로 구했다.

(히트맵의 열 : Batch 1 / Batch 2 / Batch 3 / 전체)



- **$\Delta Q(V)$ 계열 3개** (분산, 최솟값, 평균) : 세 배치 모두에서 강하고 부호가 같다. 분산은 -0.94 / -0.92 / -0.80이다.
- **충전 시간, 온도, 내부저항** : 배치마다 부호가 바뀐다. Batch 1에서 0.81인 충전 시간이 Batch 2에서는 -0.94다.
- **초기 용량** (cycle 2, cycle 100) : 배치 안에서는 -0.27 ~ 0.41로 약하다. 전체에서 -0.5 안팎으로 나오는 것은 배치 간 용량 수준과 수명이 함께 다르기 때문이며, 셀 단위의 관계가 아니다.

5.2. 가장 강한 관계 식별

수명과 가장 강한 관계를 보이는 피처는 $\Delta Q(V)$ 의 분산(로그)이다.


- 학습 배치인 Batch 1에서 상관계수의 절댓값이 가장 크다 (-0.94). 원논문이 보고한 -0.93과 같은 수준이다.
- 세 배치 모두에서 부호가 같고 강도가 유지된다 (-0.94 / -0.92 / -0.80). 이런 피처는 $\Delta Q(V)$ 계열뿐이다.
- 두 번째로 강한 충전 시간은 Batch 1에서 0.81이지만, Batch 2와 3에서는 충전 시간이 거의 일정해(약 10분) 관계가 유지되지 않는다 (-0.94 / 0.55).

Batch 1에서 강한 피처가 아니라 배치가 바뀌어도 유지되는 피처를 골라야 한다. 그 기준을 만족하는 것은 $\Delta Q(V)$ 의 분산이다.

한계. Batch 2의 -0.92는 newstructure 9개 셀과 나머지 30개를 구분하는 효과가 대부분이다. 수명이 392 ~ 514로 좁은 30개 셀 안에서는 -0.38로 약해진다.

5.3. 다중공산성 문제 확인

학습 배치인 Batch 1에서 피처 간 상관계수를 구했다. 히트맵에서 진한 색으로 나타나는 묶음이 네 개 있다.



- **$\Delta Q(V)$ 통계값 3종** : 분산, 최솟값, 평균이 서로 -0.95, -0.93, 0.99로 사실상 같은 정보다. 셋을 함께 넣으면 계수가 불안정해진다.
- **$\Delta Q(V)$ 와 충전 시간** : -0.82, 0.78, 0.78. Batch 1에서는 두 피처가 함께 움직인다. 같이 넣으면 Batch 1에서는 효과가 나뉘어 잡히는 데, 충전 시간이 일정한 Batch 2와 3에서는 그 배분이 맞지 않을 수 있다.
- **온도 2종** : 평균 온도와 최고 온도가 0.96이다.
- **용량 2종** : cycle 2 용량과 cycle 100 용량이 0.92다.

대응. 묶음마다 대표 피처 하나만 사용한다 ($\Delta Q(V)$ 분산, 평균 온도, cycle 2 용량). 여러 피처를 함께 쓸 때는 규제가 있는 선형 모델(Ridge, Elastic Net)을 사용한다. 학습 셀이 41개뿐이므로 피처 수는 적게 유지한다.

모델 설계 전략

예측 목적. 배터리 셀 1개의 초기 100 사이클 측정값으로, 그 셀이 EOL(0.88 Ah)에 도달할 때까지의 총 사이클 수를 예측한다. Batch 1로 학습하고 Batch 2로 평가한다.

0. EDA에서 전략으로

EDA 질문	발견	시사점	전략 반영
1. 수명 분포	세 배치 모두 오른쪽으로 긴 꼬리. Batch 2는 77%가 Batch 1의 최솟값(534)보다 짧음	학습 범위 밖을 예측해야 함	target 로그 변환, 범위 밖 예측이 가능한 선형 계열 모델
2. 열화 곡선	평탄 구간 뒤 급락. knee는 수명의 82 ~ 87% 지점이며 초기 100 사이클에는 나	초기 용량 값으로는 수명을 구분할 수 없음	용량 수준(QD)은 주 피처에서 제외

EDA 질문	발견	시사점	전략 반영
	타나지 않음		
3. $\Delta Q(V)$	log 분산과 log 수명의 상관관계 -0.94 / -0.92 / -0.80	초기 100 사이클에서 수명을 구분하는 신호	$\Delta Q(V)$ 분산을 핵심 피처로 사용
4. 충전 조건	Batch 1에서는 충전 시간이 강한 변수 (0.79). Batch 2·3은 충전 시간이 약 10분으로 일정	배치가 바뀌면 관계가 유지되지 않음	정책명은 사용하지 않음. 충전 시간은 보조 후보로만 검토
5. 상관관계	배치 간에 부호가 유지되는 것은 $\Delta Q(V)$ 계열뿐. ΔQ 통계값끼리 0.93 ~ 0.99 상관	피처가 서로 중복됨, 학습 셀은 41개	피처 수를 적게, 규제 선형 모델

1. Feature Engineering

피처는 세 가지 기준으로 고른다. 초기 100 사이클 안에서 계산할 수 있을 것, 배치가 바뀌어도 수명과 관계가 유지될 것, 단일 사이클의 측정 이상값에 흔들리지 않을 것.

구분	피처	계산	근거
핵심	$\Delta Q(V)$ 분산 (로그)	$\log_{10} \text{var}(Q_{100}(V) - Q_{10}(V))$	세 배치 모두에서 수명과 강한 음의 상관 (-0.94 / -0.92 / -0.80)
보조 후보	초기 용량 변화	cycle 100 용량 - cycle 2 용량	최단 수명 셀은 100 사이클 안에 이미 용량이 감소
보조 후보	충전 시간	초기 100 사이클의 중앙값	Batch 1에서 0.79. 단, Batch 2·3에서는 값이 일정해 효과를 검증한 뒤 채택
보조 후보	평균 온도, 내부저항 변화	초기 100 사이클의 평균, cycle 100 - cycle 2	Batch 1에서 약한 상관. 배치 간 부호가 일정하지 않아 검증 후 채택
제외	충전 정책명	-	배치 간에 거의 겹치지 않고, 같은 정책도 배치에 따라 수명이 다름
제외	$\Delta Q(V)$ 최솟값·평균	-	분산과 사실상 같은 정보 (-0.95, -0.93)
제외	용량의 절대 수준	-	배치마다 수준이 달라(1.06 ~ 1.09 Ah) 배치 차이가 그대로 들어감
제외	cycle 100 이후의 값, knee point	-	입력 범위를 벗어남 (누수)

보조 후보는 Batch 1 내부 검증에서 핵심 피처 하나만 쓴 모델보다 나아질 때만 채택한다.

2. Regression vs Classification

처음에는 Classification을 목표로 검토했다. 제조 직후 단수명 셀을 빠르게 걸러내는 것이 현장에서 가장 직접적인 활용이기 때문이다. 그러나 이 데이터에서는 분류 모델을 직접 학습할 수 없어, **Regression을 선택하고 그 모델로 분류 문제를 우회해서 푼다.**

	Regression	Classification
Target	$\log_{10}(\text{cycle_life})$	cycle_life $\geq$ 550이면 1
입력 범위	초기 100 사이클	초기 5 사이클
평가 지표	MAPE (%) (원래 단위로 되돌려 계산)	F1-Score, Accuracy

Classification을 직접 학습할 수 없는 이유는 두 가지다.

- **학습 데이터에 단수명 셀이 없다.** 550 사이클 미만인 셀이 Batch 1에 1개(41개 중), Batch 2에 30개(39개 중)다. 단수명 클래스를 학습할 수 없고, 내부 검증에서 F1을 계산할 수도 없다.
- **초기 5 사이클에는 수명 신호가 없다.** cycle 2 대비 $\Delta Q(V)$ 분산과 수명의 상관을 사이클 수별로 구하면 아래와 같다. 50 사이클부터 신호가 생기고 100 사이클에서 뚜렷해진다.

사용한 사이클	5	30	50	70	100
Batch 1 상관계수	0.10	-0.49	-0.80	-0.85	-0.94

Regression은 " $\Delta Q(V)$ 분산이 클수록 수명이 짧다"는 연속적인 관계를 학습하므로, 학습 데이터에 없는 짧은 수명도 예측값으로 낼 수 있다. target에 로그를 취하는 이유는 수명 분포가 오른쪽으로 치우쳐 있고(왜도 2.14), 로그-로그에서 $\Delta Q(V)$ 분산과 직선 관계가 되기 때문이다.

우회 방법 : Regression 모델로 단수명 셀 선별. 처음 목표였던 분류 문제는 포기하지 않고, 단수명 예시 없이도 풀 수 있는 형태로 바뀌어서 시도한다.

막히는 지점	접근
학습 데이터에 단수명 셀이 없음	0/1을 직접 학습하지 않는다. Regression 모델의 예측 수명이 550 사이클 미만이면 단수명으로 판정한다
초기 5 사이클에 신호가 없음	입력을 초기 100 사이클로 늘린다. 가이드의 Classification 조건(초기 5 사이클)과 다르다는 점을 결과에 명시한다
배치가 바뀌면 판정 기준선이 어긋날 수 있음	Accuracy, F1과 함께 순위 기반 지표(AUC)를 본다. 예측 수명이 짧은 순으로 세웠을 때 실제 단수명 셀이 앞에 오는지를 평가한다

성능 리포팅의 주 지표는 MAPE이며, 분류 결과는 별도 표로 보고한다. 입력 조건이 원논문의 분류 실험(초기 5 사이클, 정확도 95.1%)과 다르므로 그 수치와 직접 비교하지 않는다.

3. Modeling Strategy

데이터 처리

항목	처리
학습 / 평가	Batch 1을 학습 데이터셋으로, Batch 2를 테스트 데이터셋으로 사용한다. Batch 3는 추가 평가에 사용한다
분할 단위	셀 단위. 한 셀의 사이클이 학습과 검증에 나뉘지 않게 한다
검증 셀 구성	수명이 긴 5개 셀이 한쪽에 몰리지 않게 수명 구간을 고려해 나눈다
품질 처리	수명을 알 수 없는 셀 제외, Batch 1의 cycle 1 제외, 불가능한 값(용량 1.3 Ah 초과, 내부저항 0) 결측 처리. 세 배치에 같은 규칙을 적용한다
변환	target과 $\Delta Q(V)$ 분산에 로그. 스케일링은 학습 데이터에서만 기준을 구해 검증·테스트에 적용한다
이상값 대응	단일 사이클 값 대신 구간 통계(중앙값)를 쓴다. 여러 셀이 동시에 튀는 구간(Batch 1의 cycle 12 ~ 13, Batch 2의 cycle 46 ~ 48, 68 ~ 75)의 값은 피쳐 계산에 쓰지 않는다
테스트 데이터	피쳐·모델을 확정한 뒤 한 번만 평가한다. Batch 2 성능을 보고 모델을 다시 고르지 않는다

후보 모델

후보	구성	선정 이유 (알고리즘 관점)	선정 이유 (데이터 관점)
1. 단일 피쳐 선형 회귀 (기준 모델)	$\log \Delta Q(V)$ 분산 1개	가장 단순하고 해석이 쉬움. 학습 범위 밖으로 직선을 연장해 예측 가능	로그-로그에서 직선 관계(-0.94). 원논문도 같은 구성의 모델을 사용

후보	구성	선정 이유 (알고리즘 관점)	선정 이유 (데이터 관점)
2. 규제 선형 회귀 (Ridge, Elastic Net)	핵심 + 보조 후보 피처	규제로 계수를 안정시키고, Elastic Net은 불필요한 피처를 걸러냄	피처 간 상관성이 높고 학습 셀이 41개뿐. 원논문도 Elastic Net 사용
3. 트리 기반 (Random Forest, Gradient Boosting)	2와 같은 피처	비선형 관계와 피처 간 상호작용을 반영	비교용. 학습 범위 밖의 값을 예측하지 못해 Batch 2에서 불리할 것으로 예상

딥러닝 등 더 복잡한 모델은 후보에서 뺀다. 학습 셀이 41개뿐이어서 과적합 위험이 크고, 핵심 피처 하나로 이미 강한 선형 관계가 확인되기 때문이다.

예상 위험과 대응

위험	근거	대응
학습 범위 밖 예측	Batch 2의 77%가 Batch 1 최솟값(534)보다 짧음	선형 계열을 주 후보로. 트리 계열과의 차이를 비교해 보고
배치 간 차이	Batch 2는 같은 $\Delta Q(V)$ 분산에서 수명이 더 짧은 쪽에 분포. 같은 정책도 배치에 따라 수명이 다름	배치에 민감한 피처(충전 시간, 용량 수준)를 줄임. Gap(Valid-Test)으로 크기를 보고하고 원인을 해석
과적합	학습 셀 41개, 피처 간 상관 0.9 이상	피처 수 최소화, 규제, 기존 모델 대비 개선이 있을 때만 피처 추가
소수 장수 셀의 영향	수명 1434 ~ 2237인 5개 셀이 분포에서 떨어져 있음	로그 변환, 잔차 분석으로 영향 확인
원논문 수치와의 비교	원논문의 테스트 배치(2017-06-30)는 이 데이터셋에 없음. Batch 2(2018-02-20)는 원논문에 없는 배치	Gap(Target-Test) 해석 시 평가 조건이 다르다는 점을 명시